

# CS131 Lecture03: 线性代数初级 Part2

by: 斯坦福大学计算机科学系

github: [https://github.com/zhaoxiongjun/CS131\\_notes\\_zh-CN](https://github.com/zhaoxiongjun/CS131_notes_zh-CN) (包含中英文版课件及相关课程视频)

## 1 向量和矩阵回顾

### 1.1 向量

列向量  $\mathbf{v} \in \mathbb{R}^{n \times 1}$  :

$$\mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix}$$

行向量  $\mathbf{v}^T \in \mathbb{R}^{1 \times n}$  : (T 表示转置操作)

$$\mathbf{v}^T = [v_1 \quad v_2 \quad \cdots \quad v_n]$$

范式:

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$$

更多关于向量和矩阵范式解释:

<https://www.zhihu.com/question/20473040/answer/102907063>

## 1.2 矩阵

一个  $m \times n$  的矩阵  $A \in \mathbb{R}^{m \times n}$ :

如果  $m=n$ , 则  $A$  是一个方阵

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \cdots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \cdots & a_{2n} \\ \vdots & & & & \vdots \\ a_{m1} & a_{m2} & a_{m3} & \cdots & a_{mn} \end{bmatrix}$$

### 1.2.1 矩阵的应用

灰度图像在每个像素有一个数值, 被存储在一个  $m \times n$  的矩阵。彩色图像每个像素有 3 个数值——红色, 绿色, 蓝色 (即对应三通道)

## 2 矩阵的初等变换

矩阵可以通过乘法以有用的方式转换向量。最简单的应用是通过缩放, 或者将一个缩放矩阵的对角线上有标量乘以向量。

我们也可以用矩阵来旋转向量。当我们把一个矩阵和一个向量相乘;得到的  $x$  坐标是原始向量点乘第一行。

为了将一个向量逆时针旋转一个角度  $\theta$ :

$$x' = \cos\theta x - \sin\theta y \text{ and}$$

$$y' = \cos\theta y + \sin\theta x$$

therefore, we multiply it by the matrix

$$M = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$

这相当于:  $P' = RP$  ( $P$  和  $P'$  指向量,  $R$  是旋转的变换矩阵  $M$ )

我们同样可以通过矩阵乘法转换一个点。比如， $p' = R_2 R_1 S p$ 。这个转换是从右往左，一层接一层。在我们的例子中，这个等于  $(R_2(R_1(Sp)))$ 。

为了翻译向量，我们必须实现一个有点粗糙的解决方案，在向量的最末端添加一个“1”。这样，使用这些“齐次坐标”，我们也可以转换向量。乘法运算的结果是将矩阵最右边的列加到各自的坐标上。均匀矩阵的底行将有  $[0 \ 0 \ 1]$  以确保元素被正确添加，并且结果向量的底行有“1”。

按照惯例，在齐次坐标系下，在进行矩阵乘法后，将结果除以最后一个坐标。

$$\begin{bmatrix} x \\ y \\ 7 \end{bmatrix} \rightarrow \begin{bmatrix} x/7 \\ y/7 \\ 1 \end{bmatrix}$$

因此，为了得到  $P(x; y) \rightarrow P' = (S_x X; S_y Y)$  的结果，我们必须首先  $P = (x; y) \rightarrow (x; y; 1)$  然后  $P' = (S_x X; S_y Y) \rightarrow (S_x X; S_y Y;$

1) 这样我们才能进行矩阵乘法  $S^*P$ 。但是，我们必须注意缩放后平移与平移后缩放是不同的。换句话说， $T^*S^*P \neq S^*T^*P$

任何旋转矩阵  $R$  都属于正规矩阵的范畴，它满足以下性质。例如， $RR^T = I$  和  $\det(R) = 1$

旋转矩阵的行总是相互垂直的 (a.k.a. 正交) 单位向量；这使得它能够满足上面提到的一些独特特性。

### 3 逆矩阵

给一个矩阵  $A$ ，它的逆矩阵  $A^{-1}$  定义如下：

$$AA^{-1} = A^{-1}A = I$$

I 表示有同样尺寸的单位矩阵

一个逆矩阵例子：

$$\begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}^{-1} = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & \frac{1}{3} \end{bmatrix}$$

矩阵不一定有逆矩阵。如果存在 $A^{-1}$ ，则称 A 为可逆或非奇异。对于可逆矩阵，一些有用的恒等式是：

- $(A^{-1})^{-1} = A$
- $(AB)^{-1} = B^{-1}A^{-1}$
- $A^{-T} \triangleq (A^T)^{-1} = (A^{-1})^T$

### 3.1 伪逆矩阵

在线性代数问题中，经常需要解 X 的  $AX=B$  方程。你需要计算 $A^{-1}$ ，然后两边相乘得到  $X=A^{-1}B$ 。在 python 中，这个命令是：`np.linalg.inv (A) *B`。然而，对于大型浮点矩阵，计算逆矩阵可能非常昂贵，而且可能不准确。对于 A，甚至都不可能存在一个逆函数。我们应该怎么做？

## 4 矩阵的秩

- 转换矩阵 A 的秩告诉您它将一个矩阵转换为多少维。
- $\text{Col-rank} (A) = A$  的线性无关列向量的最大数目。
- $\text{Row-rank} (A) = A$  的最大线性无关行向量数。列秩始终等于行秩。
- 对于转换矩阵，秩表示输出的维数。例如，如果 A 的秩为 1，则转换

$P' = AP$  指向一条直线。

- 满秩矩阵-如果  $m \times m$ , 则秩为  $m$
- 奇异矩阵-如果  $m \times m$  矩阵的秩小于  $m$ , 因为至少有一个维度正在收缩。(无法判断结果的输入值)  $\rightarrow$  对于非方形矩阵, 不存在逆矩阵。

## 5 特征向量 (SVD)

### 5.1 定义

线性变换  $A$  的特征向量  $x$  是一个非零向量, 当  $A$  作用于它时, 它不会改变它的方向。将  $A$  作用于特征向量, 用一个称为特征值的标量来缩放特征向量。

下面的方程描述了特征值和特征向量之间的关系:

$$Ax = \lambda x, \quad x \neq 0$$

### 5.2 求特征向量和特征值

如果我们要求  $A$  的特征向量, 我们可以用如下方法求解:

$$\begin{aligned} Ax &= \lambda x, \quad x \neq 0 \\ Ax &= (\lambda I)x, \quad x \neq 0 \\ (\lambda I - A)x &= 0, \quad x \neq 0 \end{aligned}$$

因为  $x$  是非零向量, 因为我们可以将上式变为:

$$|\lambda I - A| = 0$$

解这个方程给出了 A 的特征值，这些特征值可以代入原方程，找到相应的特征向量。

## 5.3 性质

- 矩阵 A 的迹线等于其特征值之和：

$$tr(A) = \sum_{i=1}^n \lambda_i$$

- 矩阵 A 的行列式等于特征值的乘积：

$$|A| = \prod_{i=1}^n \lambda_i$$

- 矩阵 A 的秩等于 A 的非零特征向量的数量。
- 一个对角矩阵 D 的特征值就等于其对角线的值

## 5.4 谱理论

### 5.4.1 定义

- 特征对是特征值及其相关特征向量的对。
- 和  $\lambda$  关联的特征空间是向量空间，其中：

$$(A - \lambda I)v = 0$$

- 矩阵 A 的谱是所有特征值的集合：

$$\sigma(A) = \{\lambda \in \mathbb{C} : \lambda I - A \text{ is singular}\}$$

$\mathbb{C}$  是所有特征值的空间

- A 的谱半径是其最大值特征值的大小：

$$\rho(A) = \max\{|\lambda_1|, \dots, |\lambda_n|\}$$

### 5.4.2 定理：谱半径

Spectral radius is bounded by the infinity norm of a matrix:

$$\rho(A) = \lim_{k \rightarrow \infty} \|A^k\|^{1/k}$$

*Proof:*

$$|\lambda|^k \|\mathbf{v}\| = \|\lambda^k \mathbf{v}\| = \|A^k \mathbf{v}\|$$

By the Cauchy-Schwarz inequality ( $\|\mathbf{u}\mathbf{v}\| \leq \|\mathbf{u}\| \cdot \|\mathbf{v}\|$ ):

$$|\lambda|^k \|\mathbf{v}\| \leq \|A^k\| \cdot \|\mathbf{v}\|$$

Since  $\mathbf{v} \neq 0$ :

$$|\lambda|^k \leq \|A^k\|$$

And we thus arrive at:

$$\rho(A) = \lim_{k \rightarrow \infty} \|A^k\|^{1/k}$$

可参考：<https://blog.csdn.net/lanchunhui/article/details/50619305>

## 5.5 对角化

一个  $n \times n$  的矩阵 A 有  $n$  个线性无关特征向量时，它是可对角化的。大多数方阵是可对角化的。

- 正规矩阵是可对角化的需要满足：

$$A^* A = A A^*$$

$A^*$  是 A 的共轭矩阵（共轭复数）

- 矩阵有  $n$  个不同的特征值是可对角化的

引理：与不同特征值相关的特征向量是线性无关的。

要使矩阵 A 对角化，需要考虑其特征值和特征向量。我们可以构造矩阵 D 和 V，

其中 D 是 A 特征值的对角矩阵，V 是相应特征向量的矩阵：

$$D = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix}$$

$$V = [v_1 \quad v_2 \quad \dots \quad v_n]$$

因为我们知道：  $AV = VD$

所以我们可以把 A 对角化，通过：  $A = VDV^{-1}$

如果所有特征值都是唯一的，那么  $v$  是正交的。因为正交矩阵的逆矩阵是它的转置，所以我们可以把对角化写成：  $A = VDV^T$

## 5.6 对称矩阵

如果  $A$  是对称的，那么它的所有特征值都是实数，并且它的特征向量是正交的。

回顾上述对角化方程，我们可以通过以下方式对  $A$  进行对角化：  $A = VDV^T$

利用上面的关系，我们可以写出下面的关系式：

给定  $y = V^T x$ ：有

$$x^T Ax = x^T VDV^T x = y^T Dy = \sum_{i=1}^n \lambda_i y_i^2$$

因此，如果我们想作下面的最大化：

$$\max_{x \in \mathbb{R}^n} (x^T Ax) \quad \text{subject to } \|x\|_2^2 = 1$$

然后通过求  $A$  的最大特征值对应的特征向量，得到最大  $X$ 。



## 5.7 应用

特征值和特征向量的一些应用：

- 页面排名
- 薛定谔方程
- 主成分分析 (PCA)

## 6 矩阵演算

### 6.1 梯度

如果函数  $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ ，把矩阵  $A$  作为输入，然后返回一个实数值，那么  $f$  的梯度如下：

$$\nabla_A f(A) \in \mathbb{R}^{m \times n} = \begin{bmatrix} \frac{\partial f(A)}{\partial A_{11}} & \frac{\partial f(A)}{\partial A_{12}} & \dots & \frac{\partial f(A)}{\partial A_{1n}} \\ \frac{\partial f(A)}{\partial A_{21}} & \frac{\partial f(A)}{\partial A_{22}} & \dots & \frac{\partial f(A)}{\partial A_{2n}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f(A)}{\partial A_{m1}} & \frac{\partial f(A)}{\partial A_{m2}} & \dots & \frac{\partial f(A)}{\partial A_{mn}} \end{bmatrix}$$

每个矩阵元素都是：

$$\nabla_A f(A)_{ij} = \frac{\partial f(A)}{\partial A_{ij}}$$

梯度  $\nabla f(A)$  的大小总是和  $A$  的大小一样，因此， $A$  是一个向量  $x$  的话：

$$\nabla_x f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix}$$

## 6.2 梯度的性质

- $\nabla_x(f(x) + g(x)) = \nabla_x f(x) + \nabla_x g(x)$
- For  $t \in \mathbb{R}$ ,  $\nabla_x(tf(x)) = t\nabla_x f(x)$

## 6.3 海赛矩阵

关于  $x$  的 Hessian 矩阵可以写成如下式子或  $H$ 。它是偏导数的  $n \times n$  矩阵：

$$\nabla_x^2 f(x) \in \mathbb{R}^{n \times n} = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \frac{\partial^2 f(x)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x)}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix}$$

需要注意的是，hessian 是向量梯度的每个元素的梯度。例如，hessian 的第一

列是  $\begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \end{bmatrix}$  的梯度。

## 6.4 海赛矩阵：性质

施瓦兹定理：只要二阶导数存在且是连续的，偏导数的阶就不重要。

因此，hessian 始终是对称的：

$$\frac{\partial^2 f(x)}{\partial x_i \partial x_j} = \frac{\partial^2 f(x)}{\partial x_j \partial x_i}$$

## 6.5 计算样例

都是演算公式，看原版即可！